

Informe del experimento multiclase con dataset híbrido

Generalización de ResNet50 desde PlantVillage hacia imágenes naturales de hojas de vid

Grupo 05 · Berrios Juan Cruz, Puerta Candela y Emmanuel Orozco · 3 de septiembre de 2026

Resultado principal. Una ResNet50 entrenada exclusivamente con PlantVillage obtuvo accuracy 20,17 % y macro F1 20,50 % al evaluarse sobre 362 imágenes naturales. Con la misma arquitectura, el entrenamiento híbrido elevó esos valores a 90,61 % y 84,41 %, respectivamente, sin degradar el resultado del test controlado. La mejora aporta evidencia experimental de una reducción sustancial de la brecha de dominio.

1. Objetivo

El objetivo fue comprobar si la incorporación de fotografías naturales al entrenamiento mejora la capacidad de una red neuronal convolucional para clasificar enfermedades foliares de la vid fuera de las condiciones controladas de PlantVillage. Se compararon dos modelos ResNet50: una línea base entrenada exclusivamente con PlantVillage y un modelo entrenado con un conjunto híbrido. Ambos reconocen las mismas cuatro categorías y fueron evaluados sobre exactamente los mismos conjuntos de prueba.

2. Fuentes y construcción de los datos

2.1 Clases compatibles

El dominio controlado se obtuvo de PlantVillage. Para el dominio natural se utilizó GVLiD: *GrapeVine Leaf identification of the Diseases*, versión 5. Se conservaron exclusivamente las categorías con una correspondencia semántica entre ambas fuentes.

Etiqueta natural GVLiD	Etiqueta normalizada	Nombre utilizado
healthy	healthy_leaf	Hoja sana

esca	vl_black_measles	Esca o sarampión negro
Black rot	vl_black_rot	Podredumbre negra
leaf blight	vl_leaf_blight	Tizón foliar


2.2 Depuración y particiones

Antes de dividir GVLiD se calcularon hashes SHA-256. Se eliminaron 1.066 duplicados exactos y dos contenidos que aparecían con etiquetas contradictorias. Quedaron 2.407 fotografías naturales utilizables. La división por clase se realizó de forma determinista en 70 % para entrenamiento, 15 % para validación y 15 % para prueba, con semilla 42. El procedimiento evita que una copia exacta aparezca simultáneamente en entrenamiento y prueba.

Clase	Originales	Únicas utilizables	Train natural	Val natural	Test natural
Hoja sana	1.109	1.093	765	164	164
Esca	888	886	620	133	133
Podredumbre negra	808	97	67	15	15
Tizón foliar	672	331	231	50	50
Total	3.477	2.407	1.683	362	362

El conjunto híbrido de entrenamiento contiene las 3.250 imágenes controladas de PlantVillage y las 1.683 naturales, para un total de 4.933. La validación y el test controlados contienen 406 imágenes cada uno y se mantuvieron idénticos a los de la línea base. El test natural independiente contiene 362 fotografías y no se empleó durante el entrenamiento ni para seleccionar el checkpoint.

Ejemplos de los dominios de entrenamiento



Muestras del conjunto de entrenamiento; no pertenecen a los conjuntos de prueba.

Figura 1. Ejemplos de entrenamiento para las cuatro clases. A la izquierda, imágenes de PlantVillage en ambiente controlado; a la derecha, fotografías naturales de GVLiD. Estas muestras no pertenecen a los conjuntos de prueba.

3. Configuración experimental

Se utilizó ResNet50 inicializada con pesos ImageNet1K V2, reemplazando su capa final por cuatro salidas. Las imágenes se procesaron a 224×224 píxeles y se normalizaron con los parámetros de ImageNet. El aumento de datos se aplicó exclusivamente durante el entrenamiento: recorte aleatorio con escala 0,8–1,0, volteo horizontal, rotación de hasta 15 grados y variaciones moderadas de brillo,

contraste y saturación de 0,2. En este experimento no se aplicó CLAHE.

El entrenamiento tuvo ocho épocas iniciales con el backbone congelado y tasa de aprendizaje 0,001, seguidas por quince épocas de ajuste fino completo con tasa 0,0001. Se utilizó Adam, tamaño de lote 32, entropía cruzada ponderada por frecuencia inversa y semilla 42. El checkpoint se seleccionó por macro F1 de validación controlada. Accuracy, precision, recall, F1 por clase, macro F1, weighted F1 y matriz de confusión se calcularon sin modificar los modelos después del entrenamiento.

4. Resultados

4.1 Comparación global

Modelo	Test	Accurac y	Macro F1	Weighted F1
Solo PlantVillage	Controlado (n=406)	1,0000	1,0000	1,0000
Híbrido	Controlado (n=406)	1,0000	1,0000	1,0000
Solo PlantVillage	Natural (n=362)	0,2017	0,2050	0,2219
Híbrido	Natural (n=362)	0,9061	0,8441	0,9002

La incorporación de imágenes naturales produjo mejoras absolutas de 0,7044 en accuracy y 0,6390 en macro F1. La línea base acertó 73 de 362 imágenes naturales, mientras que el modelo híbrido acertó 328, una diferencia de 255 clasificaciones correctas. El descenso entre el test controlado y el natural fue de 79,83 puntos porcentuales para PlantVillage y de 9,39 puntos para el híbrido.

4.2 Desempeño por clase en el dominio natural

Clase	Modelo	Precisio n	Recal l	F1	n
Hoja sana	PlantVillag e	1,0000	0,012 2	0,024 1	16 4
Hoja sana	Híbrido	0,9820	1,0000	0,990 9	16 4
Esca	PlantVillag	0,7000	0,368	0,482	13

	e		4	8	3
Esca	Híbrido	0,8503	0,9398	0,8929	133
Podredumbre negra	PlantVillage	0,0528	0,9333	0,1000	15
Podredumbre negra	Híbrido	0,9231	0,8000	0,8571	15
Tizón foliar	PlantVillage	0,3200	0,1600	0,2133	50
Tizón foliar	Híbrido	0,7714	0,5400	0,6353	50




Figura 2. F1 por clase de ambos modelos sobre el mismo test natural.

Matrices de confusión sobre imágenes naturales

Filas: clase real · Columnas: clase predicha

PlantVillage · Accuracy 0.2017 · Macro F1 0.2050					Híbrido · Accuracy 0.9061 · Macro F1 0.8441				
	Sana	Esca	Podr. negra	Tizón foliar		Sana	Esca	Podr. negra	Tizón foliar
Sana	2 1.2%	9 5.5%	138 84.1%	15 9.1%	Sana	164 100.0%	0 0.0%	0 0.0%	0 0.0%
Esca	0 0.0%	49 36.8%	82 61.7%	2 1.5%	Esca	3 2.3%	125 94.0%	0 0.0%	5 3.8%
Podr. negra	0 0.0%	1 6.7%	14 93.3%	0 0.0%	Podr. negra	0 0.0%	0 0.0%	12 80.0%	3 20.0%
Tizón foliar	0 0.0%	11 22.0%	31 62.0%	8 16.0%	Tizón foliar	0 0.0%	22 44.0%	1 2.0%	27 54.0%

Figura 3. Matrices de confusión sobre el test natural. Las filas representan la clase real y las columnas la clase predicha; se informa cantidad y porcentaje dentro de cada clase real.

5. Análisis y discusión

La línea base asignó la etiqueta podredumbre negra a 138 de 164 hojas sanas, 82 de 133 casos de esca y 31 de 50 casos de tizón foliar. Por ello, su recall de podredumbre negra fue alto (0,9333), pero su precision fue de solo 0,0528. Este patrón muestra que el modelo no reconocía de forma confiable la enfermedad, sino que sobreutilizaba esa categoría frente al cambio visual del dominio.

El modelo híbrido reconoció correctamente todas las hojas sanas, 125 de 133 casos de esca y 12 de 15 casos de podredumbre negra. Su principal error residual fue la confusión entre tizón foliar y esca: 22 de los 50 casos de tizón se asignaron a esca. Aunque el F1 del tizón mejoró de 0,2133 a 0,6353, esta clase requiere mayor diversidad y una revisión de la consistencia de sus etiquetas.

Los resultados respaldan la hipótesis del artículo: el desempeño perfecto dentro de PlantVillage no predice por sí solo el comportamiento ante fotografías naturales. La mejora simultánea de accuracy, macro F1 y F1 de todas las clases indica que el entrenamiento híbrido redujo la brecha de dominio y no benefició únicamente a la clase mayoritaria.

6. Limitaciones y amenazas a la validez

Los resultados constituyen evidencia experimental preliminar y no una validación clínica o agronómica del prototipo. Una predicción no sustituye la inspección de un especialista.

- Se realizó una sola ejecución con semilla 42; falta medir variabilidad entre entrenamientos.
- El test natural está desbalanceado y contiene únicamente 15 casos únicos de podredumbre negra.
- La elevada cantidad de duplicados originales redujo el tamaño efectivo de algunas clases.

- El checkpoint híbrido fue seleccionado mediante validación controlada, no mediante validación natural.
- Los resultados perfectos en PlantVillage deben interpretarse considerando la homogeneidad visual de esa fuente.
- Falta una evaluación externa con fotografías locales independientes de ambos datasets públicos.

7. Conclusiones y próximos pasos

Manteniendo la arquitectura y las categorías, el entrenamiento híbrido elevó la exactitud natural de 0,2017 a 0,9061 y el macro F1 de 0,2050 a 0,8441, sin degradar el test controlado. Esto aporta evidencia de que la diversidad visual del entrenamiento es determinante para generalizar fuera de PlantVillage. No obstante, el bajo soporte de podredumbre negra, la confusión entre tizón foliar y esca y la ausencia de múltiples repeticiones impiden considerar el resultado definitivo.

1. Repetir ambos entrenamientos con al menos tres semillas y reportar promedio y desviación estándar.
2. Ampliar las fotografías únicas de podredumbre negra y tizón foliar.
3. Realizar una prueba externa con fotografías locales no empleadas durante el desarrollo.
4. Registrar predicción y confianza de casos externos mediante el prototipo Streamlit.
5. Evaluar calibración e incorporar una categoría de resultado incierto.

8. Fuentes y reproducibilidad

- PlantVillage: Mohanty, Hughes y Salathé (2016), *Using Deep Learning for Image-Based Plant Disease Detection*.
- GVLiD, versión 5: DOI [10.17632/wkymf8bhcg.5](https://doi.org/10.17632/wkymf8bhcg.5), licencia CC BY 4.0.
- Semilla: 42. Código de preparación: `scripts/prepare_gvlid_hybrid_data.py`.
- Evidencia: JSON y CSV de `resultados_comparacion/` y manifiestos de las particiones.